

확률·추론·추정 통합 커닝페이퍼 (7~12강)

구성: **Part I 확률(7~9강)** → **Part II 통계적 추론 입문(10강)** → **Part III 추정(11~12강)** 흐름: 확률 기초(공분산·조건부기대·점근) → 추론(베이지스 룰·분류) → 추정 (MAP/LMS/LLMS-ML). 추론·추정은 Part I의 cov/var·조건부기대를 그대로 사용.

Part I. 확률 (7~9강)

A. Derived distribution (7강) — $Y=g(X)$ 의 분포

원칙: **항상 CDF 먼저 구하고 미분.**

- 1) $F_Y(y) = P(g(X) \leq y)$
- 2) $f_Y(y) = dF_Y/dy$

이산:

$$p_Y(y) = \sum_{\{x: g(x)=y\}} p_X(x), \quad \text{otherwise } 0$$

선형 $Y=aX+b$ ($a \neq 0$, 연속):

$$f_Y(y) = (1/|a|) \cdot f_X((y-b)/a), \quad \text{otherwise } 0$$

자주 나오는 꼴:

$$Y = X^2: \quad f_Y(y) = (1/(2\sqrt{y})) \cdot [f_X(\sqrt{y}) + f_X(-\sqrt{y})] \quad (y \geq 0), \text{ otherwise } 0$$

정규 선형보존: $X \sim N(\mu, \sigma^2) \rightarrow aX+b \sim N(a\mu+b, a^2\sigma^2)$

B. 두 변수 함수 $Z=g(X,Y)$ (7강)

$$\begin{aligned} \max: \quad & P(\max(X,Y) \leq z) = P(X \leq z)P(Y \leq z) \quad (\text{둘 다 } \leq z) \\ \min: \quad & \text{CCDF가 편함 } P(\min > w) = P(X > w)P(Y > w) \quad (\text{둘 다 } > w) \end{aligned}$$

C. Convolution: $Z=X+Y, X \perp Y$ (7강)

$$\begin{aligned} \text{이산:} \quad & p_Z(z) = \sum_x p_X(x) \cdot p_Y(z-x) \\ \text{연속:} \quad & f_Z(z) = \int f_X(x) \cdot f_Y(z-x) dx \\ \text{정규합:} \quad & N(\mu_x, \sigma_x^2) + N(\mu_y, \sigma_y^2) = N(\mu_x + \mu_y, \sigma_x^2 + \sigma_y^2) \quad (\text{독립}) \end{aligned}$$

D. Covariance / Correlation (7~8강)

$$\begin{aligned} \text{cov}(X,Y) &= E[XY] - E[X]E[Y] \\ \rho(X,Y) &= \text{cov}(X,Y) / (\sigma_X \cdot \sigma_Y), \quad -1 \leq \rho \leq 1 \\ \text{cov}(X,X) &= \text{var}(X) \\ \text{cov}(aX+b, Y) &= a \cdot \text{cov}(X,Y) \quad (\text{상수 } b \text{ 무관, } a \text{ 는 1제곱}) \\ \text{cov}(X, Y+Z) &= \text{cov}(X,Y) + \text{cov}(X,Z) \\ \text{var}(X+Y) &= \text{var}(X) + \text{var}(Y) + 2\text{cov}(X,Y) \\ \text{var}(\sum X_i) &= \sum \text{var}(X_i) + \sum_{i \neq j} \text{cov}(X_i, X_j) \end{aligned}$$

- 독립 $\Rightarrow$ uncorrelated(cov=0). **역은 거짓.**
- $|\rho|=1 \Leftrightarrow$ 완전 선형관계 ($X-\mu_x = c(Y-\mu_y)$)

Cauchy-Schwarz:

$$(E[XY])^2 \leq E[X^2] \cdot E[Y^2]$$

E. 조건부 기댓값/분산 (8강)

$$\begin{aligned} E[X|Y], \text{ var}[X|Y] &\text{ 는 "Y의 함수 = 랜덤변수"} \\ E[X|Y=y], \text{ var}[X|Y=y] &\text{ 는 "숫자"} \end{aligned}$$

$$\begin{aligned} \text{반복기대 (iterated):} \quad & E[E[X|Y]] = E[X] \\ \text{전분산 (LTV):} \quad & \text{var}[X] = E[\text{var}(X|Y)] + \text{var}(E[X|Y]) \end{aligned}$$

- LTV 두 항 모두 ≥ 0 . (그룹내 변동 + 그룹간 변동)

F. Random sum (8강) — $Y = X_1 + \dots + X_N$, N 도 랜덤

조건: X_i iid (평균 μ , 분산 $\text{var}[X_i]$), $X_i \perp N$

$$E[Y] = E[N] \cdot \mu$$

$$\text{var}[Y] = E[N] \cdot \text{var}[X_1] + \mu^2 \cdot \text{var}[N] \quad (\text{둘째 항 빼먹지 말 것})$$

G. 점근 거동 (9강) — $S_n = X_1 + \dots + X_n$, X_i iid (μ, σ^2)

합과 표본평균:

$$E[S_n] = n\mu, \quad \text{var}[S_n] = n\sigma^2$$

$$M_n = S_n/n, \quad E[M_n] = \mu, \quad \text{var}[M_n] = \sigma^2/n$$

WLLN (약한 큰 수의 법칙):

$$n \rightarrow \infty \text{ 면 } \text{var}[M_n] \rightarrow 0 \rightarrow M_n \rightarrow \mu \quad (\text{확률 수렴})$$

스케일 $1/n \rightarrow$ 결정론적 세계

CLT (중심극한정리):

$$Z_n = (S_n - n\mu) / (\sigma\sqrt{n}) \rightarrow N(0, 1) \quad (\text{분포 수렴})$$

X_i 분포가 무엇이든 성립. 스케일 $1/\sqrt{n} \rightarrow$ 정규분포 세계

표준화 일반식: $Y = (X - \mu)/\sigma \rightarrow$ 평균 0, 분산 1.

Part II. 통계적 추론 입문 (10강)

0. 문제 분류 (먼저 판단)

unknown이 유한개 후보 중 하나 $\rightarrow$ Hypothesis testing (오결정 확률 최소화)

unknown이 연속(무한) 값 중 하나 $\rightarrow$ Estimation (참값에 가까운 값 찾기)

θ 를 랜덤으로 봄 + prior 있음 $\rightarrow$ Bayesian

θ 를 모르는 상수로 봄 (prior X) $\rightarrow$ Classical

용어 대응(본질 동일): hypothesis testing/estimation = classification/regression = detection/estimation

1. 핵심 용어

Likelihood	$p(x; \theta) = P(\text{data} \mid \theta)$	$\leftarrow \theta$ 가정 하에 데이터가 나올 확률
Prior	$p_\theta(\theta) / f_\theta(\theta)$	$\leftarrow$ 관측 전 θ 의 분포
Posterior	$p(\theta x) / f(\theta x)$	$\leftarrow$ 관측 후 θ 의 분포 = Bayesian의 완전한 답

- **Likelihood $\neq$ 확률**: θ 바뀌가며 계산한 값들의 합은 1 아님 (정규화 안 됨)
- Bayesian의 답은 **분포 전체**(posterior). 숫자 하나 필요할 때만 point estimate(MAP/LMS, 11강)

2. 두 방식의 결정 규칙

Classical (ML):	likelihood 큰 쪽 선택	$\text{argmax}_\theta p(x; \theta)$
Bayesian:	posterior 큰 쪽 선택	$\text{argmax}_\theta p(\theta x)$

- **prior가 uniform이면 두 결론 일치** (Bayesian $\supset$ Classical)

3. 베이즈 룰 (★핵심) — 4가지 버전

$$p(\theta|x) = \text{prior} \cdot \text{likelihood} / \text{evidence}$$

규칙: Θ 이산 $\rightarrow p_\Theta$, 분모는 Σ_Θ' / Θ 연속 $\rightarrow f_\Theta$, 분모는 $\int d\theta'$. X 이산 $\rightarrow p$, 연속 $\rightarrow f$.

[Θ 이산 X 이산]	$p(\theta x) = p_\theta(\theta) \cdot p(x \theta) / p_X(x), \quad p_X(x) = \Sigma_\theta' p_\theta(\theta') p(x \theta')$
[Θ 이산 X 연속]	$p(\theta x) = p_\theta(\theta) \cdot f(x \theta) / f_X(x), \quad f_X(x) = \Sigma_\theta' p_\theta(\theta') f(x \theta')$
[Θ 연속 X 연속]	$f(\theta x) = f_\theta(\theta) \cdot f(x \theta) / f_X(x), \quad f_X(x) = \int f_\theta(\theta') f(x \theta') d\theta'$
[Θ 연속 X 이산]	$f(\theta x) = f_\theta(\theta) \cdot p(x \theta) / p_X(x), \quad p_X(x) = \int f_\theta(\theta') p(x \theta') d\theta'$

- 분모(evidence)는 정규화 상수 $\rightarrow$ argmax 비교엔 무시 가능, 실제 값 필요할 때만 계산(전확률 정리)

4. 대표 예제 — 편향 동전 HHH

설정: $\theta \in \{1/4, 3/4\}$, 3번 던져 모두 앞면(HHH). Bernoulli: $P(H)=\theta, P(T)=1-\theta$, otherwise 0

Classical: $P(\text{HHH}|\frac{3}{4}) = (\frac{3}{4})^3 = 27/64, \quad P(\text{HHH}|\frac{1}{4}) = (\frac{1}{4})^3 = 1/64 \rightarrow 27\text{배} \rightarrow \theta = 3/4$

Bayesian (prior 1/2씩):

evidence $P(\text{HHH}) = (\frac{27}{64})(\frac{1}{2}) + (\frac{1}{64})(\frac{1}{2}) = 7/32$

posterior $P(\frac{3}{4}|\text{HHH}) = 27/28, \quad P(\frac{1}{4}|\text{HHH}) = 1/28 \rightarrow \theta = 3/4$

5. Beta prior (확률값 $\theta \in [0,1]$ 추론 시 자주 씬)

$f_{\theta}(\theta) = \theta^{\alpha-1}(1-\theta)^{\beta-1} / B(\alpha, \beta) \quad (\theta \leq \theta \leq 1), \text{ otherwise } 0$
평균 = $\alpha/(\alpha+\beta)$, $Beta(1,1) = \text{Uniform}[0,1]$

- **Conjugate prior**: m회 중 앞면 k회 관측 $\rightarrow$ posterior = $Beta(\alpha+k, \beta+(m-k))$
- 사전·사후가 같은 꼴 $\rightarrow$ recursive(순차) 추론에 유리

Part III. 추정 (11~12강)

0. 세계관 구분 (먼저 판단)

θ 가 랜덤 + prior 있음 $\rightarrow$ Bayesian: MAP / LMS / LLMS
 θ 가 모르는 상수 (prior X) $\rightarrow$ Classical: ML

1. Bayesian: posterior 먼저

posterior $p(\theta|x) \propto p(x|\theta) \cdot p(\theta)$ (분모 $p(x)$ 는 정규화 상수, argmax엔 무관)

추정	공식	posterior에서
MAP	$\hat{\theta} = \text{argmax}_{\theta} p(\theta x)$	봉우리(mode)
LMS	$\hat{\theta} = E[\theta X=x]$	평균(mean)

- MAP 실전: $p(x|\theta)p(\theta)$ 를 θ 로 미분=0 (또는 log 취하고 미분). 분모 무시.
- LMS 실전: posterior 구해서 평균. 관측 없으면 $\hat{\theta}=E[\theta]$.

2. LLMS (선형 LMS) ★최빈출

$\hat{\theta}_L = E[\theta] + (\text{cov}(\theta, X) / \text{var}(X)) \cdot (X - E[X])$
 $= E[\theta] + \rho \cdot (\sigma_{\theta} / \sigma_X) \cdot (X - E[X])$

$\rho = \text{cov}(\theta, X) / (\sigma_{\theta} \cdot \sigma_X)$
 $a = \text{cov}(\theta, X) / \text{var}(X), \quad b = E[\theta] - a \cdot E[X]$

- **필요한 것: 평균·분산·공분산만** (분포 전체 불필요)
- $X = E[X]$ 면 보정항 0 $\rightarrow \hat{\theta}_L = E[\theta]$

3. MSE 값 (셋 비교)

관측 없음: $MSE = \text{var}[\theta]$
LMS: $MSE = E[\text{var}(\theta|X)] = \text{var}[\theta] - \text{var}(E[\theta|X])$ (전역 최소)
LLMS: $MSE = (1 - \rho^2) \cdot \text{var}[\theta]$

항상: $MSE_{LMS} \leq MSE_{LLMS} \leq \text{var}[\theta]$
 $\rho=0 \rightarrow$ 데이터 쓸모X ($MSE=\text{var}[\theta]$), $|\rho|=1 \rightarrow MSE=0$

★ 평균 MSE vs 조건부 MSE — 혼동 주의 (바깥 $E[\cdot]$ 유무로 구분)

전체(평균) MSE : $E[\text{var}(\theta|X)] = \sum_x \text{var}(\theta|X=x) \cdot p_X(x)$ $\leftarrow$ 모든 관측 평균
조건부 MSE : $\text{var}(\theta|X=x_0) = E[(\theta - \hat{\theta}_M(x_0))^2 | X=x_0]$ $\leftarrow$ 특정 관측 하나

- "given $X=x_0$ " 처럼 **조건이 불고 바깥 평균이 없으면** $\rightarrow$ 그냥 $\text{var}(\theta|X=x_0)$ (평균 X)
- 위 박스의 $E[\text{var}(\theta|X)]$ 는 그 조건부 분산을 **모든 x에 대해 평균낸 것** (= 전역 최소 MSE)
- 둘은 일반적으로 값이 다름. 문제에 " $E[\cdot | X=x_0]$ " 만 있으면 조건부 한 값.
- 예 (PSP 12.2.1 (h)): $e^*(-3) = E[(X - \hat{x}_M(-3))^2 | Y=-3] = \text{var}(X|Y=-3) = 2/9$ (특정 y, 평균 아님)

LLMS MSE — 두 형태는 같은 식 (시험지 표지에 둘 다 등장)

$e^*_L = (1 - \rho^2) \cdot \text{var}[\theta] = \text{var}[\theta] - \text{cov}(\theta, X)^2 / \text{var}(X)$

- 유도: $(1-\rho^2)\text{var}[\theta] = \text{var}[\theta] - \rho^2\text{var}[\theta]$, 그리고 $\rho^2 = \text{cov}^2/(\text{var}[\theta] \cdot \text{var}(X)) \rightarrow \rho^2\text{var}[\theta] = \text{cov}^2/\text{var}(X)$ ($\text{var}[\theta]$ 약분) $\rightarrow$ 두 번째 형태.
- **쓰는 법**: ρ 를 안 구했으면 둘째 형태($\text{var}[\theta] - \text{cov}^2/\text{var}(X)$)가 빠름. ρ 를 이미 구했으면 첫 형태.
- 예 (PSP 12.2.1): $\text{var } X=2/3, \text{cov}=7/6, \text{var } Y=5 \rightarrow e^*_L = 2/3 - (7/6)^2/5 = 71/180 \approx 0.394 \rightarrow$ 검산: $\rho^2 = \text{cov}^2/(\text{var}X \cdot \text{var}Y) = 49/120, (1-49/120)(2/3) = 71/180 \checkmark$

4. Classical: ML estimator

$$\hat{\theta}_{ML} = \operatorname{argmax}_{\theta} p_X(x_1, \dots, x_n; \theta) \quad (\text{likelihood 최대화})$$

독립이면 log우도 합 최대화:

$$\hat{\theta}_{ML} = \operatorname{argmax}_{\theta} \sum \log p_{X_i}(x_i; \theta) \quad \rightarrow \theta \text{로 미분}=0$$

- 실전: 우도 곱 $\rightarrow \log \rightarrow \theta$ 미분=0 $\rightarrow \theta$ 풀기
- **MAP $\leftrightarrow$ ML**: prior가 uniform(균등)이면 MAP = ML

5. 자주 쓰는 결과/도구

$$\text{LTV (반복기대): } E[X] = E[E[X|\theta]]$$

$$\text{Total variance: } \operatorname{var}(X) = E[\operatorname{var}(X|\theta)] + \operatorname{var}(E[X|\theta])$$

$$\operatorname{cov}(\theta, X) = E[\theta X] - E[\theta]E[X]$$

$$E[(\theta - c)^2] \text{ 최소} \Leftrightarrow c = E[\theta]$$

결합PDF 모멘트 — 주변밀도 안 만들고 직접 적분 (LOTUS)

$$E[X] = \iint x \cdot f_{\{X,Y\}}(x,y) \, dx \, dy \quad (E[Y], E[XY] \text{ 도 동일 패턴})$$

$$E[XY] = \iint x \cdot y \cdot f_{\{X,Y\}}(x,y) \, dx \, dy$$

- f_X 만들어 푸는 것 = 이중적분에서 **한 변수를 먼저 적분한 중간 단계**일 뿐 (Fubini). 별개 방법 아님, 결과 항상 같음.
- x 먼저: $\int x(\int f \, dy)dx \leftrightarrow y$ 먼저: $\int x(\int f \, dx)dy \rightarrow$ 둘 다 같은 $E[X]$
- **적분 쉬운 순서를 골라라**. 삼각영역($0 \leq x \leq y \leq 1$)이면 보통 안쪽 $x: 0 \rightarrow y$ 가 깔끔.
- 연속 LLMS는 결국 이 적분으로 $E[X], E[Y], \operatorname{var}, \operatorname{cov}$ 4개만 뽑아 §2 공식에 대입.
- 예 (PSP 12.2.4, $f=2(y+x)$ on $0 \leq x \leq y \leq 1$): $E[X]=5/12$, $E[Y]=3/4$, $\operatorname{var}Y=3/80$, $\operatorname{cov}=1/48 \rightarrow a=\operatorname{cov}/\operatorname{var}Y=5/9$, $b=E[X]-a \cdot E[Y]=0 \rightarrow \hat{X}_L(Y)=(5/9)Y$